FACULDADE DE TECNOLOGIA SENAI FLORIANÓPOLIS

CURSO DE GRADUAÇÃO EM CIÊNCIA DE DADOS E INTELIGÊNCIA ARTIFICIAL

ENTREGA 2 - MVP PARCIAL
MAPA LÓGICO DOS DADOS E SCHEMA FÍSICO PRELIMINAR
BANCO DE DADOS UNIFICADO PARA O IST AMBIENTAL

Projeto Aplicado II (PJAII) - 2026/1

Natureza do documento: entregável parcial, estruturado como MVP de modelagem de dados. O objetivo é disponibilizar um material defensável e utilizável pela equipe, mesmo antes da carga integral de todas as bibliotecas públicas.

Campo	Conteúdo
Stakeholder	Instituto SENAI de Tecnologia Ambiental (IST Ambiental) - Blumenau/SC
Escopo desta versão	Modelo lógico unificado + schema físico PostgreSQL preliminar + estratégia de integração progressiva de fontes públicas
Fontes efetivamente analisadas	Plano de Trabalho; IDENTIFICACAO.xlsx; ABUND.xlsx; Compostos_final.xlsx; amostra real de PubChem XML
Status	Entregável parcial, consistente e operacionalmente aproveitável, porém ainda sem carga massiva das bibliotecas públicas
Autor do material	ChatGPT, a pedido do usuário, consolidando as decisões técnicas discutidas

Florianópolis - 2026

1. Objetivo do documento

Este documento foi preparado para servir como uma versão entregável da Entrega 2 do Projeto Aplicado II, atendendo de forma parcial, mas tecnicamente consistente, ao requisito de modelagem e arquitetura de banco de dados do projeto do IST Ambiental.

O foco aqui não é executar a carga completa das bibliotecas públicas, e sim formalizar um desenho de banco de dados robusto o suficiente para suportar: (a) os dados gerados pelo software analítico do IST; (b) a futura ingestão de, no mínimo, bibliotecas públicas químicas e ontológicas; e (c) o cruzamento entre candidatos locais e compostos externos para posterior priorização Top 5.

Em outras palavras, este entregável foi escrito para ser apresentado como um MVP parcial: não é o ponto final da modelagem, mas já é um ponto de partida suficientemente grande, organizado e defensável para avaliação acadêmica e continuidade técnica.

1.1 Interpretação do critério de aceite da Entrega 2

Pelo plano de trabalho e pela imagem do quadro de avaliação compartilhada, a Entrega 2 exige essencialmente três coisas: extração/ingestão de múltiplas fontes, elaboração do mapa lógico dos dados e especificação do schema do banco de dados unificado.

2	Extração: Ingerir dados de múltiplas fontes (dados brutos, Excel de critérios e bases públicas: PubChem, ChEBI, etc.) e criar o mapa lógico	15%	Mapa lógico dos dados e schema do banco de dados unificado	Implementar projetos lógico e físico de banco de dados; Especificar requisitos de dados	Resolução de Problemas Complexos: Analisar demandas industriais	Entregou schema. Entregou mapas lógicos. Integrou múltiplas fontes de dados(pelo menos 2 fontes de dados)

Figura 1 - Recorte do critério de avaliação da Entrega 2.

A solução proposta neste relatório foi construída exatamente para atender esse recorte. O modelo considera múltiplas fontes já conhecidas do projeto, organiza essas fontes em camadas e produz um schema relacional preliminar em PostgreSQL, com espaço explícito para evolução futura.

1.2 O que este MVP entrega agora

- diagnóstico real das planilhas do IST já enviadas nesta conversa;
- leitura estrutural de uma amostra real do PubChem em XML;
- definição de uma arquitetura em camadas: staging, núcleo analítico e referência externa;
- mapa lógico dos dados com entidades, atributos e relacionamentos;
- schema físico preliminar em PostgreSQL, acompanhado de script SQL anexo;
- regras de negócio e decisões de modelagem alinhadas ao RF01, RF02 e RF03 do plano.

1.3 O que ainda fica como continuidade

- carga massiva e saneamento completo das bibliotecas públicas;
- ajuste fino de dicionários de taxonomia, ontologia e usos por fonte;
- mapeamento automatizado e heurístico dos candidatos locais para compostos externos;
- motor probabilístico do Top 5 e painéis de visualização, previstos para entregas posteriores.

2. Base empírica utilizada para a modelagem

A modelagem abaixo não foi escrita apenas com base em suposição teórica. Ela parte de arquivos reais do projeto, já disponíveis nesta conversa, e de uma inspeção pontual de um arquivo real do PubChem. Isso permite justificar a estrutura proposta a partir de evidência empírica, ainda que a solução permaneça parcial.

Fonte	Tipo	Como foi usada neste MVP
Plano_de_Trabalho_PJ 2 - Rascunho.pdf	Documento institucional	Define o problema, o cronograma e os requisitos RF01, RF02 e RF03.
IDENTIFICACAO.xlsx	Saída do software do IST	Mostra múltiplos candidatos por feature, scores e atributos químicos locais.
ABUND.xlsx	Saída do software do IST	Mostra abundância por feature e por replicata dinâmica.
Compostos_final.xlsx	Catálogo curado interno	Mostra uma camada semântica de compostos/metabólitos já interpretados.
Compound_029500001_030000000.xml.gz	PubChem Compound XML	Exemplo real de estrutura hierárquica de uma biblioteca pública.

2.1 Achados quantitativos principais

Achado	Valor observado
Planilha de Identificação	38011 linhas e 1063 features únicas
Planilha de Abundância	1104 linhas e 1104 features únicas
Interseção pela chave Compound	962 features em comum entre Identificação e Abundância
Features apenas na Identificação	101
Features apenas na Abundância	142
Replicatas detectadas	12 colunas dinâmicas (1.1, 1.2, 2.1, 2.2, 3.1, 3.2, 4.1, 4.2, 5.1, 5.2, 6.1, 6.2)
Candidatos por feature na Identificação	média 35.76, mediana 13, máximo 344
Catálogo curado interno	200 entradas (100 (Acetato) + 100 (Metanol))

Esses números por si só já justificam a necessidade de um modelo relacional mais cuidadoso. A Identificação e a Abundância não podem ser tratadas como uma única tabela plana e perfeitamente coincidente, porque a sobreposição real encontrada nas chaves Compound não é total. Além disso, a presença de 12 replicatas explícitas na amostra real mostra que a solução precisa lidar com estrutura dinâmica, e não com colunas fixas codificadas manualmente.

2.2 Implicações diretas de modelagem

- A feature analítica precisa ser a entidade central do domínio, porque é ela que conecta identificação, abundância e enriquecimento externo.
- Uma mesma feature pode possuir muitos candidatos locais; portanto, a relação entre feature e candidato é do tipo 1:N.
- As colunas 1.1, 1.2, 2.1 ... 6.2 não devem permanecer como colunas no modelo final; elas precisam ser convertidas em linhas, via entidade de replicata e tabela fato de abundância.

- Como a interseção entre Identificação e Abundância não é total, o banco precisa registrar presença/ausência por fonte, sem perder linhas que apareçam somente em um dos lados.
- O PubChem XML analisado apresenta estrutura hierárquica e semi-estruturada; por isso a camada de biblioteca pública precisa combinar staging bruto com tabelas canônicas normalizadas.

3. Diagnóstico técnico das fontes analisadas

3.1 Estrutura observada na planilha de Identificação

A planilha de Identificação funciona como uma lista de candidatos locais por feature. O campo Compound atua como chave técnica do sinal observado. Para um mesmo Compound, existem diversas linhas, cada uma com Compound ID, fórmula, score, erro de massa, similaridade isotópica e descrição textual distintas.

Coluna	Papel na modelagem
Compound	Chave técnica da feature no arquivo e principal candidato a chave de integração.
Compound ID	Identificador local/origem do candidato; não deve substituir a chave da feature.
Adducts	Atributo do candidato local.
Formula	Atributo do candidato local e campo útil para o match com bibliotecas.
Score / Fragmentation Score / Isotope Similarity / Mass Error (ppm)	Conjunto de métricas para priorização local e futura heurística do Top 5.
Description / Link	Metadados textuais do candidato.
Neutral mass (Da) / m/z / Retention time (min)	Metadados físico-analíticos associados à feature.

3.2 Estrutura observada na planilha de Abundância

A planilha de Abundância traz uma linha por feature, mas agora com um bloco de replicatas como colunas. Esse padrão é típico de dado analítico ainda não normalizado: o arquivo é excelente para operação humana e exportação do software, mas inadequado para persistência relacional sem transformação.

Coluna / grupo	Papel na modelagem
Compound	Chave de integração com a feature.
Neutral mass (Da) / m/z / Retention time (min)	Metadados físico-analíticos consolidados.
Chromatographic peak width (min)	Atributo complementar da feature.
Identifications	Quantidade de identificações associadas à feature no arquivo.
Replicatas 1.1 a 6.2	Precisam ser convertidas em registros na tabela core.abundance_measurement.

3.3 Estrutura observada no catálogo curado interno

O arquivo Compostos_final.xlsx não se comporta como dado bruto analítico, mas como uma camada semântica já interpretada pela equipe. Ele contém nomes de compostos/metabólitos, solvente, modo

de ionização, categoria química, metabolismo e via metabólica. Por isso, ele foi tratado no desenho como catálogo curado complementar, e não como substituto das tabelas analíticas.

Elemento	Interpretação
ID	Código curado interno do catálogo.
Metabólito/Composto	Nome semântico do composto.
Solvente / Modo de Ionização	Contexto experimental da curadoria.
Categoria química	Classificação textual curada.
Metabolismo / Via metabólica	Metadados semânticos, úteis para referência e validação.

3.4 Estrutura observada no arquivo de exemplo do PubChem

Foi inspecionada uma amostra real do arquivo PubChem Compound Full XML enviado nesta conversa. O primeiro bloco de composto veio organizado em segmentos como PC-Compound_id, PC-Compound_atoms, PC-Compound_bonds, PC-Compound_coords, PC-Compound_charge, PC-Compound_props, PC-Compound_count. Esse achado é relevante porque mostra que a biblioteca pública não é uma tabela plana simples. Há um núcleo identificador, mas também listas de átomos, ligações, coordenadas, propriedades e contagens.

Essa estrutura reforça duas decisões de modelagem do MVP: primeiro, preservar o payload bruto em staging; segundo, criar tabelas canônicas de composto externo, propriedades e identificadores, evitando tanto a perda de informação quanto a explosão prematura de colunas pouco estáveis.

4. Premissas arquiteturais do banco unificado

- A entidade central do domínio é a feature analítica, e não o composto externo. O software do IST detecta primeiro um sinal, e somente depois surgem candidatos e hipóteses de correspondência.
- O banco precisa ser capaz de guardar simultaneamente o dado bruto, o dado normalizado e o dado enriquecido; por isso foi adotada uma arquitetura em camadas.
- As replicatas são dinâmicas. Logo, o modelo físico final precisa transformar colunas em linhas para permitir crescimento sem remodelagem estrutural.
- Bibliotecas públicas possuem formatos heterogêneos. Assim, o projeto precisa de staging bruto e de uma camada canônica comum para comparação.
- Nem toda integração ocorrerá de uma vez. O desenho deve ser incremental, permitindo começar com PubChem e adicionar HMDB, ChEBI e FooDB sem quebra estrutural.

4.1 Visão em camadas

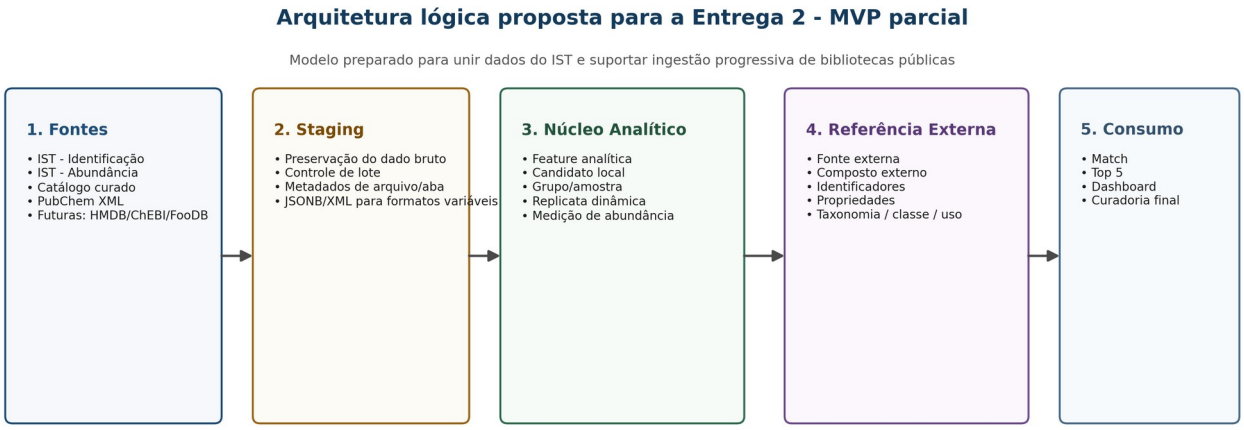

Figura 2 - Arquitetura lógica em camadas proposta para o banco unificado.

A camada stg preserva o formato original; a camada core concentra a verdade operacional do projeto; a camada ref guarda compostos externos e seus metadados; e a camada de consumo/match sustenta comparação, priorização e visualização. Essa separação permite rastreabilidade e reduz o risco de perda de informação durante o ETL.

5. Mapa lógico dos dados

O mapa lógico abaixo organiza o problema em torno da feature analítica e separa claramente o que é dado local do IST do que é referência externa.

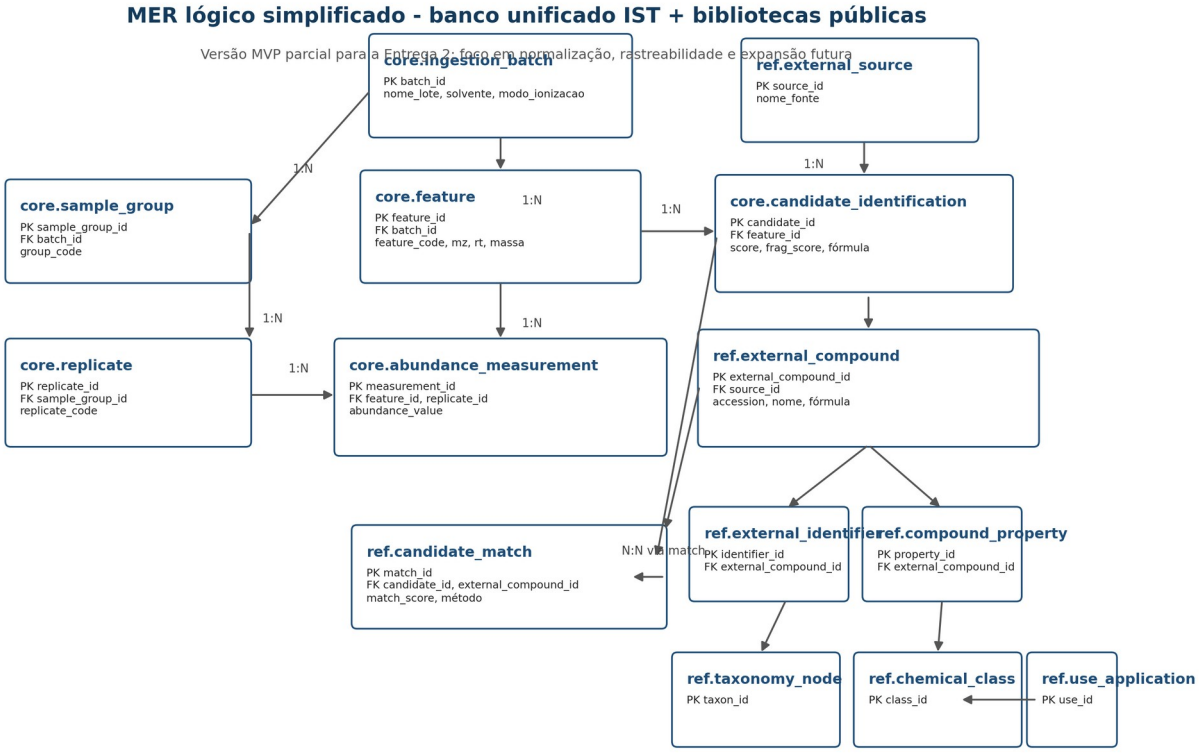

Figura 3 - MER lógico simplificado para a Entrega 2 - MVP parcial.

5.1 Entidades centrais do núcleo analítico

Entidade	Função no modelo	Observação-chave
core.ingestion_batch	Agrupa a importação e o contexto do lote.	Permite rastrear solvente, modo de ionização e origem.
core.feature	Representa o sinal analítico central.	É a âncora de integração entre identificação e abundância.
core.sample_group	Representa o grupo principal de amostra.	Abstrai o primeiro nível do código de replicata.
core.replicate	Representa cada replicata individual.	Resolve a dinamicidade das colunas 1.1, 1.2 etc.
core.abundance_measurement	Guarda o valor de abundância por feature e replicata.	É a tabela fato da camada analítica.
core.candidate_identification	Guarda os candidatos locais vindos da planilha de identificação.	Suporta a relação 1:N entre feature e candidatos.

5.2 Entidades centrais da referência externa

Entidade	Função no modelo	Observação-chave
ref.external_source	Catálogo das fontes públicas.	Permite múltiplas bibliotecas no mesmo banco.
ref.external_compound	Registro canônico do composto externo.	Normaliza CID, HMDB ID, ChEBI ID etc.
ref.external_identifier	Identificadores alternativos e sinônimos.	Evita replicar colunas especializadas no composto principal.
ref.compound_property	Propriedades químicas/físicas flexíveis.	Aceita atributos heterogêneos por biblioteca.
ref.taxonomy_node / ref.compound_taxonomy	Origem biológica, espécie, família, gênero, reino.	Atende ao pedido do IST por taxonomia associada.
ref.chemical_class / ref.compound_class	Ontologia e classificação química.	Atende ao requisito de ontologia/classificação.
ref.use_application / ref.compound_use	Usos e aplicações conhecidas.	Atende ao requisito de levantamento de usos.

5.3 Entidade de cruzamento

A tabela ref.candidate_match é a ponte entre o mundo local do IST e o mundo das bibliotecas públicas. Ela não presume que um candidato local corresponda a apenas um composto externo, nem que um composto externo corresponda a apenas um candidato. Isso é importante porque o processo real é ambíguo e iterativo.

Entidade	Finalidade
ref.candidate_match	Guardar o resultado do match entre candidato local e composto externo, com método, score, status e evidências técnicas.

6. Dicionário de dados do MVP

A seguir, cada entidade do MVP é descrita com seu propósito e com os principais atributos definidos no schema físico preliminar. Este bloco foi mantido intencionalmente detalhado para que a Entrega 2 já tenha corpo suficiente como documento técnico.

6.1 core.ingestion_batch

Controla cada carga/importação processada pelo projeto, agrupando arquivos, solvente, modo de ionização e metadados do lote.

Atributo	Tipo	Chave	Descrição
batch_id	bigserial	PK	Identificador interno do lote/importação.
batch_name	varchar(120)		Nome amigável do lote analítico.
solvent	varchar(80)		Solvente predominante do lote, quando conhecido.
ionization_mode	varchar(20)		Modo de ionização do lote (positivo, negativo ou híbrido).
source_notes	text		Observações operacionais do lote.
created_at	timestamp		Data/hora de criação do registro.

6.2 stg.identification_row

Espelha as linhas da planilha de Identificação do software do IST antes da normalização.

Atributo	Tipo	Chave	Descrição
identification_row_id	bigserial	PK	Identificador técnico da linha em staging.
batch_id	bigint	FK	Lote ao qual a linha pertence.
source_sheet	varchar(120)		Nome da aba de origem.
source_row_number	integer		Número da linha original do Excel.
compound_code	varchar(100)		Chave da feature no arquivo de origem (Coluna A).
source_compound_id	varchar(120)		Compound ID informado pelo software/origem local.
adducts	varchar(255)		Adutos identificados.
molecular_formula	varchar(120)		Fórmula molecular candidata.
score	numeric(10,4)		Score-base do software.
fragmentation_score	numeric(10,4)		Score de fragmentação.
mass_error_ppm	numeric(12,6)		Erro de massa em ppm.
isotope_similarity	numeric(12,6)		Similaridade isotópica.

link_url	text		Link externo informado na linha.
description	text		Descrição textual do candidato.
neutral_mass_da	numeric(18,8)		Massa neutra em Da.
mz	numeric(18,8)		Razão massa/carga.
retention_time_min	numeric(12,6)		Tempo de retenção em minutos.
raw_payload	jsonb		Linha original preservada em JSON.

6.3 stg.abundance_row

Preserva a planilha de Abundância antes da operação de melt, mantendo as replicatas dinâmicas em JSONB.

Atributo	Tipo	Chave	Descrição
abundance_row_id	bigserial	PK	Identificador técnico da linha em staging.
batch_id	bigint	FK	Lote ao qual a linha pertence.
source_sheet	varchar(120)		Nome da aba de origem.
source_row_number	integer		Número da linha no arquivo Excel.
compound_code	varchar(100)		Chave da feature no arquivo de abundância.
neutral_mass_da	numeric(18,8)		Massa neutra em Da.
mz	numeric(18,8)		Razão massa/carga.
retention_time_min	numeric(12,6)		Tempo de retenção em minutos.
chrom_peak_width_min	numeric(12,6)		Largura cromatográfica do pico.
identifications_total	integer		Quantidade total de identificações informadas.
replicate_payload	jsonb		Objeto JSON com as colunas dinâmicas 1.1, 1.2, 2.1 etc.
raw_payload	jsonb		Linha original preservada em JSON.

6.4 stg.curated_catalog_row

Preserva linhas do catálogo curado interno (Compostos_final.xlsx) antes da deduplicação e padronização semântica.

Atributo	Tipo	Chave	Descrição
catalog_row_id	bigserial	PK	Identificador técnico da linha em staging.

batch_id	bigint	FK	Lote ou referência lógica de importação.
source_sheet	varchar(120)		Aba de origem do catálogo.
catalog_code	varchar(80)		Código do catálogo curado.
compound_name	text		Nome do metabólito/composto.
solvent	varchar(80)		Solvente informado.
ionization_mode	varchar(20)		Modo de ionização informado.
chemical_category	varchar(150)		Categoria química textual.
metabolism_note	text		Bloco de metabolismo/observação.
pathway_note	text		Via metabólica textual.
raw_payload	jsonb		Linha original em JSON.

6.5 stg.pubchem_compound_raw

Armazena o payload bruto da biblioteca PubChem (outra biblioteca poderá usar tabela equivalente), preservando o XML para auditoria/reprocessamento.

Atributo	Tipo	Chave	Descrição
pubchem_raw_id	bigserial	PK	Identificador técnico da carga crua.
batch_id	bigint	FK	Lote lógico de importação pública.
source_file_name	varchar(255)		Arquivo XML.gz de origem.
pubchem_cid	bigint		CID extraído quando disponível.
xml_payload	xml		Bloco XML bruto do PC-Compound.
loaded_at	timestamp		Data/hora de carga em staging.

6.6 core.feature

Representa o sinal/feature analítica central do domínio; é a entidade-âncora para unificar identificação e abundância.

Atributo	Tipo	Chave	Descrição
feature_id	bigserial	PK	Identificador interno da feature.
batch_id	bigint	FK	Lote em que a feature foi observada.
feature_code	varchar(100)		Código/chave da feature (Coluna A).
neutral_mass_da	numeric(18,8)		Massa neutra consolidada.
mz	numeric(18,8)		Razão massa/carga

			consolidada.
retention_time_min	numeric(12,6)		Tempo de retenção consolidado.
chrom_peak_width_min	numeric(12,6)		Largura cromatográfica, quando disponível.
source_identification_count	integer		Qtd. de identificações informadas no arquivo de abundância.
present_in_identification	boolean		Indica se houve presença no arquivo de identificação.
present_in_abundance	boolean		Indica se houve presença no arquivo de abundância.

6.7 core.sample_group

Representa o grupo principal da amostra (ex.: 1, 2, 3, 4, 5, 6), abstraindo a estrutura de replicatas dinâmicas.

Atributo	Tipo	Chave	Descrição
sample_group_id	bigserial	PK	Identificador do grupo de amostra.
batch_id	bigint	FK	Lote ao qual o grupo pertence.
group_code	varchar(40)		Código textual do grupo/amostra.
group_description	text		Descrição opcional do grupo.

6.8 core.replicate

Representa cada replicata do grupo de amostra, permitindo crescimento dinâmico sem criar colunas fixas no modelo físico.

Atributo	Tipo	Chave	Descrição
replicate_id	bigserial	PK	Identificador da replicata.
sample_group_id	bigint	FK	Grupo ao qual a replicata pertence.
replicate_code	varchar(40)		Código completo da replicata, como 1.1 ou 6.2.
replicate_order	integer		Ordem técnica da replicata dentro do grupo.
replicate_type	varchar(40)		Tipo de replicata, quando definido.

6.9 core.abundance_measurement

Tabela fato da abundância, relacionando feature e replicata com o valor medido.

Atributo	Tipo	Chave	Descrição
measurement_id	bigserial	PK	Identificador da medição.

feature_id	bigint	FK	Feature medida.
replicate_id	bigint	FK	Replicata em que houve a medição.
abundance_value	numeric(20,8)		Valor de abundância.
measurement_note	text		Campo opcional para observações.

6.10 core.candidate_identification

Armazena cada candidato local oriundo da planilha de identificação para uma feature específica.

Atributo	Tipo	Chave	Descrição
candidate_id	bigserial	PK	Identificador do candidato local.
feature_id	bigint	FK	Feature à qual o candidato pertence.
source_compound_id	varchar(120)		Compound ID local/origem do software.
adducts	varchar(255)		Adutos sugeridos.
molecular_formula	varchar(120)		Fórmula molecular candidata.
score	numeric(10,4)		Score-base do software.
fragmentation_score	numeric(10,4)		Score de fragmentação.
mass_error_ppm	numeric(12,6)		Erro de massa em ppm.
isotope_similarity	numeric(12,6)		Similaridade isotópica.
description	text		Descrição textual do candidato.
link_url	text		Link externo existente na fonte.
candidate_rank_local	integer		Posição local opcional após ordenação.

6.11 ref.external_source

Catálogo de bibliotecas/fontes externas utilizadas para enriquecimento e comparação.

Atributo	Tipo	Chave	Descrição
source_id	bigserial	PK	Identificador da fonte externa.
source_name	varchar(60)		Nome da fonte, ex.: PubChem, HMDB, ChEBI, FooDB.
source_type	varchar(40)		Tipo lógico da fonte (química, ontológica, taxonômica etc.).
base_url	text		URL base ou referência de origem.
notes	text		Observações da

			integração.

6.12 ref.external_compound

Registro canônico do composto vindo de uma biblioteca externa, desacoplado do candidato local do IST.

Atributo	Tipo	Chave	Descrição
external_compound_id	bigserial	PK	Identificador interno do composto externo.
source_id	bigint	FK	Fonte externa do composto.
external_accession	varchar(120)		Identificador externo (CID, HMDB ID, ChEBI ID etc.).
preferred_name	text		Nome preferencial do composto.
molecular_formula	varchar(120)		Fórmula molecular.
exact_mass	numeric(18,8)		Massa exata, quando disponível.
canonical_smiles	text		SMILES canônico.
inchi	text		InChI.
inchikey	varchar(64)		InChIKey.
raw_payload	jsonb		Payload normalizado ou parcialmente bruto para reuso.

6.13 ref.external_identifier

Armazena identificadores alternativos e sinônimos técnicos associados a um composto externo.

Atributo	Tipo	Chave	Descrição
identifier_id	bigserial	PK	Identificador interno do registro.
external_compound_id	bigint	FK	Composto externo relacionado.
identifier_type	varchar(40)		Tipo do identificador (CID, InChIKey, CAS, synonym, registry etc.).
identifier_value	text		Valor do identificador.
is_primary	boolean		Marca se o identificador é o principal para a fonte.

6.14 ref.compound_property

Tabela flexível para propriedades físico-químicas e metadados quantitativos/qualitativos de um composto externo.

Atributo	Tipo	Chave	Descrição
property_id	bigserial	PK	Identificador da

			propriedade.
external_compound_id	bigint	FK	Composto externo relacionado.
property_name	varchar(120)		Nome da propriedade.
property_value_text	text		Valor textual da propriedade.
property_value_num	numeric(20,8)		Valor numérico da propriedade, quando aplicável.
unit	varchar(40)		Unidade de medida.
evidence_source	varchar(120)		Origem lógica da propriedade dentro da biblioteca.

6.15 ref.taxonomy_node

Representa nós taxonômicos ou de origem biológica associados às moléculas.

Atributo	Tipo	Chave	Descrição
taxon_id	bigserial	PK	Identificador do nó taxonômico.
source_id	bigint	FK	Fonte externa da taxonomia.
external_taxon_id	varchar(120)		Identificador externo do táxon.
taxon_name	varchar(255)		Nome do táxon.
taxon_rank	varchar(40)		Nível taxonômico (espécie, gênero, família, reino etc.).
parent_taxon_id	bigint	FK	Auto-relacionamento para hierarquia taxonômica.

6.16 ref.compound_taxonomy

Tabela de ligação entre composto externo e taxonomia/origem biológica.

Atributo	Tipo	Chave	Descrição
compound_taxonomy_id	bigserial	PK	Identificador do vínculo composto-táxon.
external_compound_id	bigint	FK	Composto externo.
taxon_id	bigint	FK	Táxon relacionado.
relationship_type	varchar(60)		Tipo do vínculo, ex.: found_in, derived_from.
evidence_note	text		Observação/evidência do vínculo.

6.17 ref.chemical_class

Armazena a ontologia ou classificação química da molécula em forma hierárquica.

Atributo	Tipo	Chave	Descrição
chemical_class_id	bigserial	PK	Identificador da classe química.
source_id	bigint	FK	Fonte externa da classificação.
external_class_id	varchar(120)		Identificador externo da classe.
class_name	varchar(255)		Nome da classe química.
class_system	varchar(80)		Sistema de classificação, ex.: ChEBI, MeSH, ClassyFire-like.
parent_class_id	bigint	FK	Classe pai para hierarquia.

6.18 ref.compound_class

Tabela de ligação entre composto externo e classe química/ontologia.

Atributo	Tipo	Chave	Descrição
compound_class_id	bigserial	PK	Identificador do vínculo composto-classe.
external_compound_id	bigint	FK	Composto externo.
chemical_class_id	bigint	FK	Classe química relacionada.
evidence_note	text		Observação ou evidência do vínculo.

6.19 ref.use_application

Catálogo de usos, aplicações ou contextos funcionais conhecidos para a molécula.

Atributo	Tipo	Chave	Descrição
use_id	bigserial	PK	Identificador do uso/aplicação.
source_id	bigint	FK	Fonte externa que descreve o uso.
use_category	varchar(120)		Categoria de uso.
use_description	text		Descrição livre do uso ou aplicação.

6.20 ref.compound_use

Tabela de ligação entre composto externo e usos/aplicações conhecidas.

Atributo	Tipo	Chave	Descrição
compound_use_id	bigserial	PK	Identificador do vínculo composto-uso.
external_compound_id	bigint	FK	Composto externo.
use_id	bigint	FK	Uso/aplicação relacionado.

evidence_note	text		Observação ou evidência do vínculo.

6.21 ref.curated_catalog_entry

Catálogo semântico interno derivado do arquivo Compostos_final.xlsx, útil como referência complementar e futura curadoria.

Atributo	Tipo	Chave	Descrição
catalog_entry_id	bigserial	PK	Identificador da entrada do catálogo.
catalog_code	varchar(80)		Código do catálogo curado.
compound_name	text		Nome do composto/metabólito.
solvent	varchar(80)		Solvente associado.
ionization_mode	varchar(20)		Modo de ionização associado.
chemical_category	varchar(150)		Categoria química textual.
metabolism_note	text		Observação de metabolismo.
pathway_note	text		Via metabólica textual.
source_sheet	varchar(120)		Aba de origem no catálogo.

6.22 ref.candidate_match

Materializa o cruzamento entre candidato local e composto externo, sustentando comparação, score e futura seleção Top 5.

Atributo	Tipo	Chave	Descrição
match_id	bigserial	PK	Identificador do match.
candidate_id	bigint	FK	Candidato local oriundo da identificação.
external_compound_id	bigint	FK	Composto externo relacionado.
match_method	varchar(60)		Método usado para o match (nome, massa, fórmula, InChIKey etc.).
match_score	numeric(10,6)		Score de similaridade/confiança do match.
match_status	varchar(30)		Estado do match: proposed, reviewed, approved, rejected.
basis_fields	jsonb		JSON com evidências técnicas do cruzamento.
is_top5_candidate	boolean		Indicador auxiliar para motores analíticos futuros.

7. Mapeamento entre colunas de origem e entidades de destino

Um ponto crítico da Entrega 2 é mostrar como as fontes reais entram no banco. Por isso, o mapeamento abaixo explicita a correspondência entre colunas dos arquivos e as estruturas propostas no schema.

7.1 Mapeamento da planilha IDENTIFICACAO.xlsx

Origem	Destino	Observação
Compound	stg.identification_row.compound_code -> core.feature.feature_code	Chave técnica da feature
Compound ID	stg.identification_row.source_compound_id -> core.candidate_identification.source_compound_id	Identificador local do candidato
Adducts	stg.identification_row.adducts -> core.candidate_identification.adducts	Atributo do candidato
Formula	stg.identification_row.molecular_formula -> core.candidate_identification.molecular_formula	Base para match por fórmula
Score	stg.identification_row.score -> core.candidate_identification.score	Score local
Fragmentation Score	stg.identification_row.fragmentation_score -> core.candidate_identification.fragmentation_score	Score de fragmentação
Mass Error (ppm)	stg.identification_row.mass_error_ppm -> core.candidate_identification.mass_error_ppm	Erro de massa
Isotope Similarity	stg.identification_row.isotope_similarity -> core.candidate_identification.isotope_similarity	Similaridade isotópica
Description	stg.identification_row.description -> core.candidate_identification.description	Descrição textual
Link	stg.identification_row.link_url -> core.candidate_identification.link_url	URL externa local
Neutral mass (Da), m/z, Retention time (min)	stg.identification_row -> core.feature	Metadados da feature

7.2 Mapeamento da planilha ABUND.xlsx

Origem	Destino	Observação
Compound	stg.abundance_row.compound_code -> core.feature.feature_code	Chave técnica da feature
Neutral mass (Da), m/z, Retention time (min)	stg.abundance_row -> core.feature	Metadados físico-analíticos
Chromatographic peak width (min)	stg.abundance_row.chrom_peak_width_min -> core.feature.chrom_peak_width_min	Atributo complementar da feature
Identifications	stg.abundance_row.identifications_to	Contador vindo da abundância

	tal -> core.feature.source_identification_count	
1.1, 1.2, ..., 6.2	stg.abundance_row.replicate_payload -> core.sample_group/core.replicate/core.abundance_measurement	Transformação melt

7.3 Mapeamento do catálogo curado Compostos_final.xlsx

Origem	Destino	Observação
ID	stg.curated_catalog_row.catalog_code -> ref.curated_catalog_entry.catalog_code	Código do catálogo
Metabólito/Composto	stg.curated_catalog_row.compound_name -> ref.curated_catalog_entry.compound_name	Nome semântico
Solvente	stg.curated_catalog_row.solvent -> ref.curated_catalog_entry.solvent	Contexto experimental
Modo de Ionização	stg.curated_catalog_row.ionization_mode -> ref.curated_catalog_entry.ionization_mode	Contexto experimental
Categoria química	stg.curated_catalog_row.chemical_category -> ref.curated_catalog_entry.chemical_category	Classificação textual
Metabolismo / Via metabólica	stg.curated_catalog_row -> ref.curated_catalog_entry	Complementos semânticos

7.4 Mapeamento do exemplo PubChem XML

Bloco de origem	Destino	Observação
PC-Compound_id	stg.pubchem_compound_raw.pubchem_cid -> ref.external_compound.external_accession	Identificador principal da fonte
PC-Compound_props	staging parser -> ref.compound_property	Propriedades físico-químicas
PC-Compound_count	staging parser -> ref.compound_property	Contagens/resumos
Identificadores derivados (InChI, InChIKey, SMILES)	parser -> ref.external_compound / ref.external_identifier	Identificação química canônica
Carga total / demais blocos	parser -> ref.external_compound.raw_payload ou tabelas auxiliares futuras	Preservação para expansão

8. Regras de negócio e cardinalidades

- Um lote de ingestão pode possuir muitas features; cada feature pertence a um único lote.

- Uma feature pode possuir zero, um ou muitos candidatos locais na planilha de identificação.
- Um grupo de amostra pode possuir muitas replicatas; cada replicata pertence a um único grupo.
- Uma feature pode ser medida em muitas replicatas; cada combinação feature-replicata deve ser única na tabela de medição.
- Um composto externo pertence a uma única fonte externa, mas cada fonte pode possuir muitos compostos.
- Um composto externo pode ter muitos identificadores alternativos, muitas propriedades, muitos vínculos taxonômicos, muitas classes químicas e muitos usos/aplicações.
- Um candidato local pode ser associado a vários compostos externos, e um composto externo pode ser associado a vários candidatos locais; a materialização disso ocorre em ref.candidate_match.
- Nenhuma linha de staging deve ser descartada sem preservação mínima do payload bruto, para manter auditabilidade do ETL.

8.1 Resposta aos requisitos do plano

Critério	Como o MVP responde
RF01 - junção de Identificação e Abundância pela Coluna A	Atendido no modelo pela entidade core.feature e pelas chaves compound_code/feature_code.
RF02 - suporte a variação dinâmica de amostras e replicatas	Atendido pela decomposição em core.sample_group, core.replicate e core.abundance_measurement.
RF03 - consulta a APIs e bases públicas	Atendido pela camada ref.external_source, ref.external_compound e suas tabelas auxiliares.
Critério da Entrega 2 - múltiplas fontes + mapa lógico + schema	Atendido de forma parcial e entregável por meio das camadas stg, core e ref, do MER lógico e do SQL anexo.

9. Schema físico preliminar (PostgreSQL)

O schema foi escrito para PostgreSQL 15+ e foi dividido em três schemas lógicos: stg, core e ref. Essa decisão não é estética; ela ajuda a separar dado bruto, dado operacional e dado de referência.

- stg: recebe e preserva as linhas quase no formato de origem, reduzindo perda de informação e facilitando auditoria;
- core: contém a verdade operacional do projeto, já normalizada para consultas, joins e dashboards;
- ref: concentra compostos externos, taxonomia, ontologia, usos e matches.

9.1 Decisões de implementação adotadas

- Uso de BIGSERIAL para chaves técnicas em função da escala potencial do projeto.
- Uso de JSONB para payloads variáveis, especialmente em staging e evidências de match.
- Uso do tipo XML no staging do PubChem, preservando o bloco bruto original.
- Índices nas chaves de integração e nos campos mais prováveis de consulta, como feature_code, external_accession e inchikey.
- Restrições UNIQUE em pares críticos, evitando duplicidade técnica de feature por lote e de medição por combinação feature-replicata.

9.2 Trecho representativo do DDL

```
-- Entrega 2 - MVP parcial
-- Schema fisico preliminar para PostgreSQL 15+
-- Projeto Aplicado II - IST Ambiental
-- Objetivo: suportar unificacao de Identificacao + Abundancia e preparar
-- integracao progressiva com bibliotecas publicas (PubChem, HMDB, ChEBI, FooDB etc.).
CREATE SCHEMA IF NOT EXISTS core;
CREATE SCHEMA IF NOT EXISTS stg;
CREATE SCHEMA IF NOT EXISTS ref;
CREATE TABLE IF NOT EXISTS core.ingestion_batch (
    batch_id              BIGSERIAL PRIMARY KEY,
    batch_name            VARCHAR(120) NOT NULL,
    solvent               VARCHAR(80),
    ionization_mode       VARCHAR(20),
    source_notes          TEXT,
    created_at            TIMESTAMP NOT NULL DEFAULT CURRENT_TIMESTAMP
);
CREATE TABLE IF NOT EXISTS stg.identification_row (
    identification_row_id BIGSERIAL PRIMARY KEY,
    batch_id              BIGINT NOT NULL REFERENCES core.ingestion_batch(batch_id),
    source_sheet          VARCHAR(120),
    source_row_number     INTEGER,
    compound_code         VARCHAR(100) NOT NULL,
    source_compound_id    VARCHAR(120),
    adducts               VARCHAR(255),
    molecular_formula     VARCHAR(120),
    score                 NUMERIC(10,4),
    fragmentation_score   NUMERIC(10,4),
    mass_error_ppm        NUMERIC(12,6),
    isotope_similarity    NUMERIC(12,6),
    link_url              TEXT,
    description           TEXT,
    neutral_mass_da       NUMERIC(18,8),
    mz                    NUMERIC(18,8),
    retention_time_min    NUMERIC(12,6),
    raw_payload           JSONB
);
CREATE TABLE IF NOT EXISTS stg.abundance_row (
    abundance_row_id      BIGSERIAL PRIMARY KEY,
    batch_id              BIGINT NOT NULL REFERENCES core.ingestion_batch(batch_id),
    source_sheet          VARCHAR(120),
    source_row_number     INTEGER,
    compound_code         VARCHAR(100) NOT NULL,
    neutral_mass_da       NUMERIC(18,8),
    mz                    NUMERIC(18,8),
    retention_time_min    NUMERIC(12,6),
    chrom_peak_width_min  NUMERIC(12,6),
    identifications_total INTEGER,
    replicate_payload     JSONB NOT NULL,
    raw_payload           JSONB
);
CREATE TABLE IF NOT EXISTS stg.curated_catalog_row (
    catalog_row_id        BIGSERIAL PRIMARY KEY,
    batch_id              BIGINT REFERENCES core.ingestion_batch(batch_id),
    source_sheet          VARCHAR(120),
    catalog_code          VARCHAR(80),
    compound_name         TEXT,
    solvent               VARCHAR(80),
    ionization_mode       VARCHAR(20),
    chemical_category     VARCHAR(150),
    metabolism_note       TEXT,
    pathway_note          TEXT,
    raw_payload           JSONB
);
CREATE TABLE IF NOT EXISTS stg.pubchem_compound_raw (
    pubchem_raw_id        BIGSERIAL PRIMARY KEY,
    batch_id              BIGINT REFERENCES core.ingestion_batch(batch_id),
    source_file_name      VARCHAR(255),
```

```
    pubchem_cid           BIGINT,
    xml_payload           XML NOT NULL,
    loaded_at             TIMESTAMP NOT NULL DEFAULT CURRENT_TIMESTAMP
);
CREATE TABLE IF NOT EXISTS core.feature (
    feature_id                    BIGSERIAL PRIMARY KEY,
    batch_id                      BIGINT NOT NULL REFERENCES core.ingestion_batch(batch_id),
    feature_code                  VARCHAR(100) NOT NULL,
    neutral_mass_da               NUMERIC(18,8),
    mz                            NUMERIC(18,8),
    retention_time_min            NUMERIC(12,6),
    chrom_peak_width_min          NUMERIC(12,6),
    source_identification_count   INTEGER,
    present_in_identification     BOOLEAN NOT NULL DEFAULT FALSE,
    present_in_abundance          BOOLEAN NOT NULL DEFAULT FALSE,
    created_at                    TIMESTAMP NOT NULL DEFAULT CURRENT_TIMESTAMP,
    CONSTRAINT uq_feature UNIQUE (batch_id, feature_code)
);
CREATE TABLE IF NOT EXISTS core.sample_group (
    sample_group_id       BIGSERIAL PRIMARY KEY,
```

Observação: o script SQL completo acompanha este relatório como arquivo anexo separado, com nome schema_postgresql_mvp_entrega2.sql.

10. Limitações assumidas nesta versão

- A modelagem foi validada empiricamente com um exemplo real do PubChem, mas ainda não com cargas completas de HMDB, ChEBI e FooDB.
- O catálogo curado interno foi modelado como referência semântica complementar, porém ainda sem chave automática de ligação com as features analíticas.
- As regras de scoring do Top 5 ainda não foram materializadas em tabela própria, pois pertencem à entrega seguinte.
- O modelo privilegia robustez estrutural e rastreabilidade; ajustes de performance podem ser refinados após testes de carga reais.

11. Conclusão executiva

Este documento entrega um MVP parcial, porém substantivo, para a Entrega 2. A proposta já define uma arquitetura de banco de dados unificado coerente com o plano de trabalho, com o comportamento real dos arquivos do IST e com a necessidade de crescimento para bibliotecas públicas.

O ponto mais importante desta solução é a escolha da feature analítica como entidade central. Essa decisão organiza corretamente o problema: primeiro o software detecta um sinal; depois surgem candidatos locais; depois ocorre o enriquecimento com bibliotecas públicas; e por fim o projeto pode calcular o ranking Top 5 e exibir resultados em dashboard.

Em termos acadêmicos, o material já é defensável como mapa lógico dos dados e schema físico preliminar. Em termos técnicos, ele também é utilizável como base para codificação imediata do ETL e da camada PostgreSQL. Portanto, mesmo sendo parcial, este entregável já cumpre o papel de destravar a continuidade do projeto com uma estrutura clara, escalável e alinhada ao que o IST Ambiental espera.

Apêndice A - Ordem recomendada de carga do ETL

Etapa	Carga / transformação	Resultado esperado
1	Inserir core.ingestion_batch	Contexto do lote criado
2	Carregar stg.identification_row	Dado bruto de identificação preservado
3	Carregar stg.abundance_row	Dado bruto de abundância preservado
4	Gerar core.feature a partir da união das chaves Compound	Lista consolidada de features
5	Gerar core.sample_group e core.replicate a partir das colunas dinâmicas	Replicatas normalizadas
6	Gerar core.abundance_measurement via melt	Tabela fato de abundância
7	Gerar core.candidate_identification	Candidatos locais vinculados às features
8	Carregar fontes externas e compostos externos	Camada de referência pronta
9	Executar matching e preencher ref.candidate_match	Base pronta para Top 5 e dashboards

Apêndice B - Observações estratégicas para a equipe

- Guilherme da Silva Anselmo pode utilizar este documento como base imediata para modelar o banco em PostgreSQL e produzir o DER em ferramenta visual.
- Guilherme Zamboni Menegacio pode usar diretamente os mapeamentos de origem para preparar o ETL com pandas, melt e pivot.
- Vinícius Joacir dos Anjos pode usar a camada ref como contrato mínimo para ingestão de PubChem, HMDB, ChEBI e FooDB.
- Samuel Silva de Rezende pode usar este material como base de apresentação parcial, justificando escopo, progresso e racional de arquitetura.